



Modelo Preditivo

MÓDULO 2 - SEMANA 4 - AULA 1



SCITI.SC

Apresentações



Barueri - São Paulo

Sou técnico em eletroeletrônica (ITB-FIEB) e bacharel em Matemática Aplicada e Computacional (USP), atualmente cursando mestrado na área de Neurociências (USP).

Atuo em projetos de pesquisa integrando Machine Learning, Psicofísica, EEG e Estatística, com foco no uso da modelagem matemática para investigar processos fisiológicos. Entre minhas principais linhas de atuação, destacam-se:

- **Visão Computacional:** Identificação de danos em plantas via modelos de imagem e padrão comportamental em modelo animal.
- **Saúde e Biologia:** Detecção de crises epiléticas em roedores.
- **Sistemas Visuais:** Análise de movimentos oculares em humanos e padrões em primatas.

<http://lattes.cnpq.br/0845927265914505>

<https://www.linkedin.com/in/felipe-souza-2ab535137/>

Machine Learning é sobre aprender com dados e resolver problemas encontrando padrões. Como a vida é feita de desafios diários, desenvolver essa mentalidade analítica nos deixa muito mais prontos para superar os obstáculos do cotidiano.

AGENDA

- Fluxo de um projeto de Machine Learning
- Análise Exploratória
- Limpeza e Tratamento de Dados
- Feature Engineering
- Isolamento de Variáveis
- Divisão Amostral com Estratificação (Treino e Teste)
- Balanceamento de Classes

Fluxo de Machine Learning

① 1. Coleta de Dados (Ingredientes Brutos)

Garbage In, Garbage Out

Ir à feira/produtor e juntar a matéria-prima (arquivos CSV, bancos SQL, APIs). Se o ingrediente estiver estragado, o prato final será ruim.

Fluxo de Machine Learning

② 2. Limpeza de Dados (Lavar e Descascar)

Tratamento de ruído

Remover sujeiras, descartar partes podres (tratar missings/NaN), retirar duplicatas e ajustar formatos para que os ingredientes possam ser usados.

Fluxo de Machine Learning

③ 3. Engenharia de Features (Cortar e Temperar)

Preparação para o algoritmo

Transformar texto em número (ex: fatiar em cubos), normalizar escalas, criar novas colunas que ajudem no sabor (ex: extrair ano/mês de uma data).

Fluxo de Machine Learning

④ 4. Treinamento do Modelo (O Cozimento no Forno)

Onde a matemática atua

AQUI entra o algoritmo preditivo! O forno (modelo) aprende a temperatura e o tempo corretos observando os dados preparados.

Fluxo de Machine Learning

⑤ 5. Validação (A Degustação do Chef)

Ajuste fino

Provar o prato antes de servir ao cliente. Testar com dados novos que o forno nunca viu para verificar se o ponto está correto.


Fluxo de Machine Learning

⑥ 6. Desdobramento / Deploy (Servir ao Cliente)

Produção real

Colocar a receita automatizada no cardápio (subir o modelo para uma API para rodar na nuvem ou no aplicativo final).

Fluxo de Machine Learning



Pipeline de Pré-Processamento de dados para *machine learning*

Síntese da preparação e transformação da matéria-prima





Figura 1 - Pipeline de processamento de dados

Fluxo de Machine Learning

- **Diversos Pipelines de Machine Learning:** Não existe um modelo certo ou errado.
- **A escolha ideal depende de:** Contexto, objetivos e ponto de vista.
- Vejamos alguns detalhes desse fluxo que merecem atenção.


Scikit Learn

scikit-learn algorithm cheat sheet




Análise exploratória de dados - Resumo

Exploração Inicial do Dataset




Análise exploratória de dados



MAGALHÃES; LIMA, 2015.

Representações gráficas podem ser utilizadas para compreender como seus dados se comportam.


Análise exploratória de dados



<https://profissaobiotec.com.br/dados-desbalanceados-ensinando-seu-modelo-maneira-certa-aprender/>

Um gráfico de barras pode ser útil para verificar se sua variável alvo é desbalanceadas.

Gráfico de Calor (Heatmap) - Correlação de Pearson



Impacto da Obesidade em Pacientes com Hipertensão Arterial Resistente e Refratária: Um Estudo Transversal

Bárbara Victória Peixoto Lima da Costa , Fábio Bulhões , Cristiano Macedo, Alex Cleber Improta-Caria , Roque Aras Júnior 

DOI: 10.36660/abc.20250627

Gráfico de Calor (Heatmap) - Correlação de Pearson

A correlação de Pearson mede o **grau de relação linear** entre duas variáveis contínuas. Ela gera um coeficiente (chamado de r) que fica estritamente entre **-1 e 1**.

- **1.0 (Correlação Positiva Perfeita):** Se a variável A aumenta, a variável B aumenta na mesma proporção. *(Ex: Quanto maior a área de uma casa, maior tende a ser o preço).*
- **0.0 (Nenhuma Correlação Linear):** O movimento da variável A não tem relação nenhuma com o movimento da variável B. *(Ex: A altura de uma pessoa e a quantidade de café que ela bebe).*
- **-1.0 (Correlação Negativa Perfeita):** Se a variável A aumenta, a variável B diminui na mesma proporção. *(Ex: Quanto maior a velocidade de um carro, menor é o tempo necessário para chegar ao destino).*

Gráfico de Calor (Heatmap) - Correlação de Pearson

O gráfico funciona como uma grade (matriz) onde cada linha e cada coluna representam uma variável do seu dataset:

1. **A Diagonal Principal:** Você vai notar que a linha diagonal que corta o gráfico do topo esquerdo ao formato inferior direito é sempre perfeita (valor 1.0 ou a cor mais intensa). Isso acontece porque ela representa a correlação da variável com ela mesma (ex: Idade vs Idade).
2. **A Paleta de Cores (Divergente):** Geralmente, os heatmaps usam uma escala onde cores quentes (como vermelho/laranja) indicam forte correlação positiva, cores frias (como azul) indicam forte correlação negativa, e cores neutras (como branco ou cinza) indicam ausência de correlação.
3. **Simetria:** O gráfico é um "espelho". O triângulo acima da diagonal principal contém exatamente as mesmas informações do triângulo abaixo dela. Afinal, a correlação entre "Altura e Peso" é a mesma entre "Peso e Altura".

Para que usamos isso no Machine Learning?

Identificar preditores fortes: Encontrar variáveis que tenham uma correlação alta (seja positiva ou negativa) com a sua **variável alvo** (o que você quer prever).

Detectar Multicolinearidade: Se duas variáveis explicativas têm uma correlação muito alta entre si (ex: acima de 0.90), significa que elas carregam a mesma informação. Pro modelo, ter as duas é redundante e pode atrapalhar algoritmos como a Regressão Linear.

O gráfico te ajuda a identificar isso, assim dependendo do contexto e de suas análises/resultados iniciais tu consegue excluir uma delas e checar se teve melhoras na predição da variável alvo.

Gráfico de Calor (Heatmap) - Correlação de Pearson

```
import pandas as pd
import seaborn as sns
import matplotlib.pyplot as plt
```

```
# Calcula a matriz de correlação de Pearson
matriz_correlacao = df.corr(method='pearson')
```

```
# Desenha o gráfico de calor
plt.figure(figsize=(10, 8))
sns.heatmap(matriz_correlacao, annot=True, cmap='coolwarm', fmt=".2f", vmin=-1,
vmax=1)
```

```
plt.title('Gráfico de Calor - Correlação de Pearson')
plt.show()
```

Gráfico de Calor (Heatmap) - Correlação de Pearson

annot=True: Exibe os números dentro de cada quadrado colorido para você saber o valor exato.

cmap='coolwarm': Usa a paleta clássica (Azul para negativo, Vermelho para positivo).


vmin=-1, vmax=1: Trava os limites do gráfico para garantir que as cores representem fielmente a escala de Pearson.

Documentação: <https://seaborn.pydata.org/generated/seaborn.heatmap.html>


Limpeza e Tratamento de Dados - Resumo

FASE 2: LIMPEZA E TRATAMENTO DE DADOS (DATA PREP) - CORRIGIDO

1 Identificação e remoção de linhas duplicadas




2 Identificação e tratamento de valores ausentes




3 Identificação de outliers com Boxplots

- O boxplot permite visualizar a distribuição dos dados e identificar possíveis outliers.
- Linha central: mediana
 - Caixa: intervalo interquartil (Q1-Q3)
 - Hastes: até $1,5 \times \text{IQR}$
 - Pontos: outliers




Objetivo da Fase 2: Garantir a qualidade dos dados, removendo duplicatas, tratando valores ausentes e identificando outliers para preparar o dataset para uma análise exploratória confiável e para a modelagem.

Feature Engineering



Adaptado de https://pt.linkedin.com/posts/venceslaumari_dados-brutos-por-si-s%C3%B3-3-apenas-pontos-activity-7378430522827571200-ljA9

Feature Engineering



<https://www.nucleoconsultoriajr.com/post/m%C3%A9tricas-o-que-s%C3%A3o-qual-sua-import%C3%A2ncia-e-como-aplic%C3%A1-la-na-minha-empresa>



<https://blog.ulbra.br/engenharia-civil-voce-conhece-essa-promissora-area/>

Lidando com variáveis categóricas

`pd.get_dummies()` (One-Hot Encoding)

Ideal para variáveis **sem ordem natural** (nominais), como cores, cidades ou estados. [\[1\]](#)

- **Como funciona:** Para cada categoria única, ele cria uma nova coluna. O valor é 1 se a categoria estiver presente e 0 caso contrário.
- **Exemplo prático:** A coluna "Cor" com as categorias "Vermelho", "Verde" e "Azul" vira três colunas (Cor_Vermelho, Cor_Verde, Cor_Azul).
- **Por que usar:** Evita que o modelo de *machine learning* assuma uma relação matemática ou hierarquia (ex: achar que "Azul" é maior ou melhor que "Vermelho" por ter um valor numérico maior).

Lidando com variáveis categóricas

```
dados = pd.DataFrame({  
    'Funcionario': ['Ana', 'Bruno', 'Carlos', 'Diana'],  
    'Cidade': ['São Paulo', 'Rio de Janeiro', 'São Paulo', 'Belo Horizonte']  
})  
  
display(dados)
```

	Funcionario	Cidade
0	Ana	São Paulo
1	Bruno	Rio de Janeiro
2	Carlos	São Paulo
3	Diana	Belo Horizonte

Lidando com variáveis categóricas

```
# Aplicando o pd.get_dummies na coluna 'Cidade'  
# 0 argumento 'dtype=int' transforma os valores booleanos (True/False) em 0 e 1  
dados_transformados = pd.get_dummies(dados, columns=['Cidade'], dtype=int)  
  
display(dados_transformados)
```

	Funcionario	Cidade_Belo Horizonte	Cidade_Rio de Janeiro	Cidade_São Paulo
0	Ana	0	0	1
1	Bruno	0	1	0
2	Carlos	0	0	1
3	Diana	1	0	0

Lidando com variáveis categóricas

drop_first - Tratamos o risco de (Multicolinearidade)

- Remove a primeira coluna criada pelo processo. Se tínhamos três categorias (L, M, H), o Pandas criará apenas duas colunas: **tipo_M** e **tipo_H**. Se ambas forem 0, implicitamente o modelo sabe que a máquina é do tipo L.

Alguns modelos matemáticos, como a **Regressão Linear**, tentam calcular um "peso" (coeficiente) exclusivo para cada coluna.

Se duas ou mais colunas trazem exatamente a mesma informação combinada, a matemática do modelo entra em colapso. O algoritmo tenta dividir por zero ou cria pesos infinitos/instáveis porque ele não consegue separar o efeito de uma coluna do efeito da outra. Isso é a **multicolinearidade**.

Lidando com variáveis categóricas

```
dados_transformados = pd.get_dummies(dados, columns=['Cidade'], dtype=int, drop_first=True)  
  
dados_transformados
```

	Funcionario	Cidade_Rio de Janeiro	Cidade_São Paulo
0	Ana	0	1
1	Bruno	1	0
2	Carlos	0	1
3	Diana	0	0

Lidando com variáveis categóricas

LabelEncoder()

Ideal para variáveis **com ordem natural** (ordinais), como escolaridade (Fundamental < Médio < Superior), níveis de dor (Leve < Moderado < Severo) ou classificações.

- **Como funciona:** Transforma cada categoria em um número inteiro único (ex: 0, 1, 2, 3) dentro da mesma coluna.
- **Exemplo prático:** A coluna "Tamanho" com "Pequeno", "Médio" e "Grande" é transformada em 0, 1 e 2.
- **Cuidado essencial:** Não utilize esta técnica para categorias sem ordem (ex: Países). Modelos lineares ou de regressão podem interpretar erroneamente que o número 2 tem o dobro da magnitude ou importância do número 1.

Lidando com variáveis categóricas

Característica	<code>get_dummies()</code>	<code>LabelEncoder()</code>
Tipo de Dado	Categórico nominal (sem ordem)	Categórico ordinal (com ordem)
Formato	Cria várias colunas binárias	Mantém uma única coluna
Relação Matemática	Sem hierarquia	Cria uma escala numérica de ordem
Melhor uso	Regressão Linear, Redes Neurais	Algoritmos baseados em árvores (Random Forest)

Isolamento de Variáveis (X e y) e Proteção contra Vazamento

```
# Separação de variáveis preditoras (X) e alvo (y)

# Crio uma lista com as colunas que eu não irei usar em X
# Outra possibilidade é filtrar só as colunas que serão úteis
recursos_excluidos = ['nomeColuna1', 'nomeColuna2', 'nomeColuna3']

X = df_codificado.drop(columns=recursos_excluidos)
y = df_codificado['falha_maquina']
```

Isolamento de Variáveis (X e y) e Proteção contra Vazamento

Aqui dividimos nosso conjunto de dados em duas entidades matemáticas fundamentais para a IA:

- **X (Variáveis Preditoras/Features):** Uma matriz contendo apenas os dados dos sensores (temperatura, rotação, torque, etc.) que o modelo usará para tentar adivinhar o comportamento da máquina.
- **y (Variável Alvo/Target):** Um vetor contendo apenas as respostas certas (se a máquina falhou ou não).
- **df.drop(columns=[...]):** Excluir colunas específicas da matriz X.

Isolamento de Variáveis (X e y) e Proteção contra Vazamento.

Motivo

Precisamos esconder a resposta final (`falha_maquina`) do nosso conjunto de perguntas (X). Se a coluna de falhas ficasse dentro de X, o modelo não aprenderia a analisar os sensores; ele simplesmente olharia para a coluna ao lado, veria a resposta e acertaria tudo. Isso se chama **Data Leakage** (Vazamento de Dados). Também removemos colunas que gerem "ruídos".

Isolamento de Variáveis (X e y) e Proteção contra Vazamento.

O que acontece se não usar?

O seu modelo sofrerá um "falso sucesso". Ele apresentará 100% de acerto durante o desenvolvimento porque está trapaceando (olhando a resposta na própria pergunta ou decorando números de série). No entanto, quando você colocá-lo para rodar em uma máquina real na fábrica, ele falhará completamente porque não aprendeu a interpretar os sensores de temperatura ou torque.

Divisão Amostral com Estratificação (Treino e Teste)

```
# Divisão amostral em Treino (80%) e Teste (20%) com estratificação
X_train, X_test, y_train, y_test = train test split(
    X, y, test_size=0.20, stratify=y, random_state=42
)
```

Divisão Amostral com Estratificação (Treino e Teste)

O comando `train_test_split` quebra suas perguntas (X) e respostas (y) em quatro pedaços separados:

- **`test_size=0.20`**: Define que 20% do seu banco de dados total será guardado em um "cofre" para ser o Teste (o exame final). Os outros 80% serão usados como o Treino (o livro de estudos).
- **`stratify=y`**: *Garante que a proporção original de falhas seja mantida rigorosamente igual tanto no pedaço de treino quanto no de teste. Se a sua base de dados histórica completa possui 4% de máquinas com falhas, a separação garantirá que o treino tenha exatamente 4% de falhas e o teste também tenha exatamente 4%.*
- **`random_state=42`**: Funciona como uma "semente" de aleatoriedade fixa. Toda vez que você ou outro cientista rodar esse código, a divisão dos dados será exatamente a mesma, garantindo consistência nos experimentos.

Divisão Amostral com Estratificação (Treino e Teste) - Resumo



O PORQUÊ (A ANALOGIA DO “SIMULADO ESCOLAR”)

Se você estudar pelas mesmas perguntas que vão cair na prova final, você não testou sua inteligência; você apenas testou sua memória (fenômeno conhecido como *overfitting*).


ANALOGIA



LIVRO DE ESTUDOS (TREINO)



PROVA FINAL (TESTE)



100 CASOS DE DOENÇAS RARAS



A **estratificação** (*stratify*) serve para garantir que o “nível de dificuldade” e a proporção de tópicos do livro de estudos sejam idênticos aos da prova final.



Resultado: Avaliação justa e confiável, pois o treino e o teste representam a mesma realidade.



O QUE ACONTECE SE NÃO USAR?

Como as quebras de máquinas são eventos raros (apenas 4% do total), uma divisão puramente aleatória sem o *stratify* corre o risco de mandar todas as máquinas que falharam para o conjunto de treino.



O seu conjunto de teste ficaria com 0% de falhas.



Você estaria testando o seu modelo em uma prova sem nenhuma pergunta sobre o problema real, gerando **métricas falsas de acurácia**.



COM STRATIFY (CORRETO)

Mantém a mesma proporção de falhas (4%)

DADOS ORIGINAIS



96% OK
4% FALHA

● OK (máquina funcionando) ● FALHA (quebra de máquina)

TREINO (80%)



TESTE (20%)



Proporção preservada.
Avaliação justa e realista.



SEM STRATIFY (ARRISCADO)

Pode não manter a proporção de falhas

DADOS ORIGINAIS



96% OK
4% FALHA

TREINO (80%)



TESTE (20%)



Nenhuma falha no teste.
Métricas de acurácia serão falsas!

Balanceamento de Classes

```
# 4. Balanceamento de classes via técnica de reamostragem (Random Under Sampling)
treino_completo = pd.concat([X_train, y_train], axis=1)
classe_normal = treino_completo[treino_completo['falha_maquina'] == 0]
classe_falha = treino_completo[treino_completo['falha_maquina'] == 1]

# Reduzindo a classe majoritária para o tamanho da minoritária
classe_normal_subamostrada = resample(
    classe_normal, replace=False, n_samples=len(classe_falha), random_state=42
)

treino_balanceado = pd.concat([classe_normal_subamostrada, classe_falha])
X_train_bal = treino_balanceado.drop(columns=['falha_maquina'])
y_train_bal = treino_balanceado['falha_maquina']
```

Balanceamento de Classes


Existem formas diferentes de lidar com esse problema, aqui, veremos uma possibilidade.

Subamostragem (*Under Sampling*).

1. Separar temporariamente o grupo de treino (os 80%) em dois subgrupos: máquinas normais (0) e máquinas que falharam (1).
2. A função `resample` entra em ação na `classe_normal`: ela descarta aleatoriamente registros de máquinas saudáveis até que a quantidade fique rigorosamente igual à quantidade de exemplos de máquinas com falha (`n_samples=len(classe_falha)`).
3. O código junta os dados novamente, criando novos conjuntos chamados `X_train_bal` e `y_train_bal` (Treino Balanceado), onde há exatamente 50% de exemplos normais e 50% de falhas.

Balanceamento de Classes - Resumo

4. BALANCEAMENTO DE CLASSES (RANDOM UNDER SAMPLING) NO TREINO



Q O que a estratégia faz exatamente

Este bloco resolve manualmente o problema do desbalanceamento através do Subamostragem (Under Sampling).

- 1 Ele separa temporariamente o seu grupo de treino (os 80%) em dois subgrupos: máquinas normais (0) e máquinas que falharam (1).
- 2 A função `resample` entra em ação na classe `normal`: ela descarta aleatoriamente registros de máquinas saudáveis até que a quantidade fique rigorosamente igual à quantidade de exemplos de máquinas com falha (`n_samples=len(classe_falha)`).
- 3 O código junta os dados novamente, criando novos conjuntos chamados X_{train_bal} e y_{train_bal} (Treino Balanceado), onde há exatamente 50% de exemplos normais e 50% de falhas.

💡 O PORQUÊ (A ANALOGIA DO "ALUNO PREGUIÇOSO")

Algoritmos de classificação buscam o caminho de menor esforço matemático para reduzir o erro geral.

Analogia:

Imagine um teste com 100 perguntas onde 96 respostas corretas são a letra "A" e apenas 4 são a letra "B". Se um aluno responder "A" em todas as questões sem ler nenhuma pergunta, ele tirará nota 96 (96% de acerto!)



PROVA (100 QUESTÕES)

- 96 questões: resposta correta = A
- 4 questões: resposta correta = B

ALUNO PREGUIÇOSO

Respondeu "A" para tudo

Acertou 96/100 (96% de acerto!)


Ele parecerá um gênio, mas na verdade ele é um ignorante preguiçoso que não aprendeu nada.

O desbalanceamento faz a IA fazer exatamente isso: ela chuta que nenhuma máquina vai quebrar e atinge 96% de acurácia.

- ★ Ao balancear os dados de estudo para 50/50, obrigamos a IA a estudar os padrões que diferenciam uma máquina boa de uma quebrada de igual para igual.

👑 REGRA DE OURO


Observe que este balanceamento é feito EXCLUSIVAMENTE nos dados de treino (X_{train} e y_{train}).



- ⚠️ O seu conjunto de testes (X_{test} e y_{test}) permanece intacto com a proporção real do mercado (96% vs 4%).
Não podemos mexer no teste, senão estaríamos mascarando a realidade do cenário em que o modelo atuará na fábrica.

⚠️ O QUE ACONTECE SE NÃO USAR?

O modelo vai ignorar completamente as falhas. Ele apresentará uma acurácia global fantástica de 96%, mas a sua taxa de acerto para prever as quebras reais das máquinas será próxima de zero.



Resultado nas previsões

Correto (normal) Errado (falha)

Métricas enganosas

ACURÁCIA GLOBAL

96%

(Parece ótimo!)

ACERTO PARA FALHAS (Recall da classe 1)

0%

(Inútil para a fábrica!)

Para a fábrica, esse modelo é inútil, pois o objetivo principal do projeto é justamente antecipar as raras quebras operacionais.

Métricas para avaliação de Modelos de Machine Learning

MÓDULO 2 - SEMANA 4 - AULA 2

Pra que usamos métricas?

Como temos certeza de que após um treinamento dado modelo realmente “aprendeu” os padrões contidos nos dados? E se aprendeu, o quão bem o fez? E dado um ou mais modelos como dizer qual deles é o melhor?

É nesse cenário que entram as métricas de avaliação de modelos, que nos permitem quantificar o desempenho dos modelos a fim de saber se nosso objetivo foi ou não alcançado.

Essa é uma aula mais densa por natureza, mas muitas das coisas legais/aplicações que vemos com Machine Learning são elaboradas tendo esse conteúdo que vamos ver como pano de fundo.

Agenda

- Quais as principais métricas para validação de modelos em ML - Regressão
 - MAE - Erro Médio Absoluto
 - MSE – Erro Quadrático Médio
 - RMSE – Raiz do Erro Quadrático Médio
 - MAPE – Erro Percentual Médio Absoluto
 - R2 – Coeficiente de Determinação
 - Exemplo ilustrativo

A Grande Divisão dos Problemas

A escolha das métricas depende exclusivamente da natureza da variável alvo (y) que você está tentando prever:

TIPO DE PROBLEMA DE MACHINE LEARNING

REGRESSÃO (Valor Contínuo)

Ex: Preço, Temperatura, Tempo

- MAE (Erro Médio Absoluto)
- MSE (Erro Quadrático Médio)
- RMSE (Raiz do Erro Quadrático Médio)
- MAPE – Erro Percentual Médio Absoluto
- R^2 (Coeficiente de Determinação)
- Análise de Resíduos

CLASSIFICAÇÃO (Categorias)

Ex: Churn (Sim/Não), Fraude, Doença

- Matriz de Confusão
- Acurácia
- Precisão
- Recall / Sensibilidade
- F1-Score
- Curva ROC & AUC

TIPO DE PROBLEMA DE MACHINE LEARNING

REGRESSÃO (Valor Contínuo)

Ex: Preço, Temperatura, Tempo

- MAE (Erro Médio Absoluto)
- MSE (Erro Quadrático Médio)
- RMSE (Raiz do Erro Quadrático Médio)
- MAPE – Erro Percentual Médio Absoluto
- R^2 (Coeficiente de Determinação)
- Análise de Resíduos

CLASSIFICAÇÃO (Categorias)

Ex: Churn (Sim/Não), Fraude, Doença

- Matriz de Confusão
- Acurácia
- Precisão
- Recall / Sensibilidade
- F1-Score
- Curva ROC & AUC


Regressão Linear Simples

Diagram illustrating the components of the simple linear regression equation:

$$Y_i = \beta_0 + \beta_1 X_i + \varepsilon_i$$

Labels and arrows pointing to the equation components:

- Variável Resposta** (Response Variable) points to Y_i .
- Intercepto Populacional** (Population Intercept) points to β_0 .
- Inclinação Populacional** (Population Slope) points to β_1 .
- Variável Preditora** (Predictor Variable) points to X_i .
- Erro Aleatório** (Random Error) points to ε_i .



$$\mu_Y = E(Y) = \beta_0 + \beta_1 X$$

$$\hat{Y}_i = b_0 + b_1 X_i \quad \text{Modelo estimado}$$

$$\varepsilon_i = Y_i - \hat{Y}_i \quad \text{Resíduo}$$

MAE - Erro Médio Absoluto

Intuitivamente:

Imagine que você é um feirante e tenta adivinhar o peso exato de sacos de frutas. No primeiro saco, você erra por 100g para mais. No segundo, erra por 100g para menos. Se somássemos os erros diretamente ($+100 + (-100)$), pareceria que seu erro médio foi zero, o que é uma ilusão.

O MAE ignora a direção do erro (se foi para mais ou para menos) e foca apenas na *distância*. Ele pega o valor absoluto de cada erro e calcula a média simples. É a resposta mais honesta e direta para a pergunta: *"Em média, quantos gramas/reais/quilômetros meu modelo erra?"*

MAE - Erro Médio Absoluto

$$MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|$$

- n : Número total de observações (amostras) no conjunto de dados.
- y_i : Valor real da observação i .
- $\hat{y}_i$: Valor predito pelo modelo para a observação i .
- $(y_i - \hat{y}_i)$: O resíduo (erro individual da predição).
- $|\cdot|$ (**Módulo/Valor Absoluto**): A operação matemática crucial. Remove o sinal negativo para evitar que erros de super estimativa e sub estimativa se cancelem mutuamente.

MAE - Erro Médio Absoluto

Impacto de Outliers:

O MAE possui uma resposta linear aos erros. Se o erro em uma única observação aumentar em 10 vezes, a contribuição desse erro para o MAE aumentará exatamente 10 vezes. Por essa razão, o MAE é robusto a outliers. Ele não hiper-penaliza pontos fora da curva.

Unidade de Medida:

O MAE preserva a mesma unidade de medida da variável original (y). Se a variável alvo é "Preço da Casa em Reais (R\$)", o MAE será dado em Reais (R\$). Isso facilita imensamente a comunicação com partes interessadas não técnicas (gestores, diretores e clientes).

MAE - Erro Médio Absoluto

Quando Usar vs. Quando Evitar

- **Quando Usar:**

- Quando a interpretação do negócio exige uma métrica simples e direta na unidade original.
- Quando a base de dados possui outliers ou ruídos que não devem distorcer drasticamente a avaliação do modelo.
- Cenários onde um erro duas vezes maior tem exatamente o dobro do custo de negócio.

- **Quando Evitar:**

- Quando erros grandes são inaceitáveis ou desproporcionalmente custosos (ex: predição de tempo de parada em UTIs, estimativas de carga elétrica em subestações).

TIPO DE PROBLEMA DE MACHINE LEARNING

REGRESSÃO (Valor Contínuo)

Ex: Preço, Temperatura, Tempo

- MAE (Erro Médio Absoluto)
- — MSE (Erro Quadrático Médio)
- RMSE (Raiz do Erro Quadrático Médio)
- MAPE – Erro Percentual Médio Absoluto
- R^2 (Coeficiente de Determinação)
- Análise de Resíduos

CLASSIFICAÇÃO (Categorias)

Ex: Churn (Sim/Não), Fraude, Doença

- Matriz de Confusão
- Acurácia
- Precisão
- Recall / Sensibilidade
- F1-Score
- Curva ROC & AUC

MSE — Erro Quadrático Médio (Mean Squared Error) & LSE (Least Squared Error)

Esclarecimento sobre a sigla LSE (pois vocês podem encontrar esse termo ao buscar na internet):

LSE (*Least Squared Error* ou Mínimos Quadrados) refere-se originalmente ao **princípio/critério de otimização matemática** (método dos Mínimos Quadrados Ordinários — OLS). Em termos de métrica de avaliação, o cálculo do LSE acumulado na amostra é formalmente a **Soma dos Erros Quadráticos** (SSE), enquanto o **MSE** é a média dessa soma. Na prática e em livros texto, **MSE** é a métrica padrão utilizada.

MSE — Erro Quadrático Médio (Mean Squared Error) & LSE (Least Squared Error)

Intuitivamente:

Pense no MSE como um **sistema de multas progressivas do trânsito**. Se você ultrapassa o limite de velocidade em 5 km/h, paga uma multa leve (ex: R\$ 25). Mas se ultrapassa em 50 km/h, você não paga 10 vezes o valor da primeira multa; paga 100 vezes mais (ex: R\$ 2.500) e tem a carteira suspensa.

O MSE aplica essa mesma lógica: erros pequenos são "perdoados", enquanto erros grandes recebem uma punição/peso exponencial.

MSE — Erro Quadrático Médio

$$MSE = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

- $(y_i - \hat{y}_i)^2$: O erro de cada observação elevado ao quadrado.
- **Por que elevar ao quadrado?**
 1. **Eliminação do Sinal:** O quadrado torna todo número negativo em positivo ($(-5)^2 = 25$), assim como o módulo no MAE.
 2. **Propriedade Derivável:** A função quadrática $f(x) = x^2$ é contínua e suavemente derivável em todos os pontos, inclusive em 0. A função módulo $|x|$ possui um "ponto angular" (uma quina) em $x = 0$, o que dificulta o uso direto por algoritmos de otimização baseados em gradiente (como o Gradient Descent).
 3. **Penalização Não Linear:** Um erro de valor 2 vira 4. Um erro de valor 10 vira 100.

MSE — Erro Quadrático Médio

Impacto de Outliers:

O MSE é extremamente sensível a outliers. A presença de um único ponto com resíduo elevado dominará a soma total do erro, podendo distorcer toda a avaliação do modelo e fazer com que o algoritmo foque em ajustar esse ponto em detrimento da maioria dos dados.

Unidade de Medida:

O MSE resulta na unidade da variável alvo ao quadrado (y^2). Se y for medido em "Reais (R\$)", o MSE será expresso em "Reais²". Isso torna a interpretação direta do valor do MSE humanamente ininteligível no contexto de negócios.

MSE — Erro Quadrático Médio

Quando Usar vs. Quando Evitar

- **Quando Usar:**

- Como **função de perda** (*loss function*) durante o treinamento de modelos matemáticos (como Regressão Linear ou Redes Neurais), devido à sua diferenciabilidade analítica.
- Quando qualquer erro grande traz consequências catastróficas.

- **Quando Evitar:**

- Para apresentação final de performance a equipes de negócios.
- Quando os dados contêm discrepâncias ou erros de medição conhecidos que não representam o comportamento padrão.

TIPO DE PROBLEMA DE MACHINE LEARNING

REGRESSÃO (Valor Contínuo)

Ex: Preço, Temperatura, Tempo

- MAE (Erro Médio Absoluto)
- MSE (Erro Quadrático Médio)
-  — RMSE (Raiz do Erro Quadrático Médio)
- MAPE – Erro Percentual Médio Absoluto
- R^2 (Coeficiente de Determinação)
- Análise de Resíduos

CLASSIFICAÇÃO (Categorias)

Ex: Churn (Sim/Não), Fraude, Doença

- Matriz de Confusão
- Acurácia
- Precisão
- Recall / Sensibilidade
- F1-Score
- Curva ROC & AUC

RMSE — Raiz do Erro Quadrático Médio

Intuitivamente:

O RMSE é a solução pragmática para a limitação de interpretabilidade do MSE. Imagine que você usou o sistema de multas progressivas (MSE) para penalizar rigorosamente os erros grandes, mas no final precisa apresentar o relatório do erro em Reais, e não em "Reais²". O RMSE aplica a raiz quadrada ao MSE para trazer a penalização progressiva de volta à moeda corrente.

RMSE — Raiz do Erro Quadrático Médio

$$RMSE = \sqrt{MSE} = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}$$

- $\sqrt{\cdot}$ **(Raiz Quadrada)**: Anula a dimensão quadrática introduzida no MSE, trazendo a ordem de grandeza da métrica de volta à escala original de y .

RMSE — Raiz do Erro Quadrático Médio

Impacto de Outliers:

O RMSE mantém a **alta sensibilidade a outliers** herdada do MSE. Embora a raiz quadrada reduza a magnitude do número final, a penalização pesada ocorrida *antes* do somatório permanece gravada na métrica.

Regra de ouro: Em um mesmo conjunto de dados, o RMSE sempre será maior ou igual ao MAE ($\text{RMSE} \geq \text{MAE}$). Quanto maior for a diferença entre RMSE e MAE, maior é a variância dos erros e a presença de erros grandes no modelo.

Unidade de Medida:

O RMSE retorna à mesma unidade de medida da variável alvo (y).

RMSE — Raiz do Erro Quadrático Médio

Quando Usar vs. Quando Evitar

- **Quando Usar:**

- Quando você quer uma métrica legível na unidade original, mas ainda precisa penalizar fortemente grandes divergências.
- Métrica padrão da indústria em competições de Ciência de Dados (ex: Kaggle) para problemas de regressão.

- **Quando Evitar:**

- Quando a base de dados tem dados ruidosos que não devem influenciar a média de desempenho aceitável do sistema.

TIPO DE PROBLEMA DE MACHINE LEARNING

REGRESSÃO (Valor Contínuo)

Ex: Preço, Temperatura, Tempo

- MAE (Erro Médio Absoluto)
- MSE (Erro Quadrático Médio)
- RMSE (Raiz do Erro Quadrático Médio)
- ➡ — MAPE – Erro Percentual Médio Absoluto
- R^2 (Coeficiente de Determinação)
- Análise de Resíduos

CLASSIFICAÇÃO (Categorias)

Ex: Churn (Sim/Não), Fraude, Doença

- Matriz de Confusão
- Acurácia
- Precisão
- Recall / Sensibilidade
- F1-Score
- Curva ROC & AUC

MAPE — Erro Percentual Médio Absoluto

Intuitivamente:

Imagine que você tem uma loja e prevê as vendas de um produto que custa R\$ 10,00 e de outro que custa R\$ 1.000,00. Se o seu modelo errar R\$ 5,00 no primeiro produto, é um erro de 50% (enorme!). Se errar R\$ 5,00 no segundo, é um erro de 0,5% (desprezível!).

O **MAPE** calcula quanto o erro representa em **porcentagem** em relação ao valor real de cada observação. É a métrica favorita dos gestores, pois responde: *"Em média, nosso modelo erra em quantos por cento do valor real?"*

MAPE — Erro Percentual Médio Absoluto

$$MAPE = \frac{1}{n} \sum_{i=1}^n \left| \frac{y_i - \hat{y}_i}{y_i} \right| \times 100\%$$

- $\frac{y_i - \hat{y}_i}{y_i}$: O erro relativo (proporção do erro em relação ao valor real y_i).
- $|\cdot|$: Garante que porcentagens para mais e para menos não se cancelem.
- $\times 100\%$: Converte a proporção decimal em percentual.

MAPE — Erro Percentual Médio Absoluto

Impacto de Outliers:

- **Valores Pequenos de y_i :** Se o valor real y_i for muito próximo de zero, a divisão por y_i fará a porcentagem explodir para números gigantescos, distorcendo o MAPE.
- **Se $y_i = 0$:** O MAPE **não pode ser calculado** (divisão por zero!).

Unidade de Medida:

A unidade é percentual (%). É uma métrica adimensional e relativa.

MAPE — Erro Percentual Médio Absoluto

Quando Usar vs. Quando Evitar

- **Quando Usar:** Previsão de demanda, vendas ou estoques onde a interpretação em porcentagem faz sentido direto para a operação e onde todos os valores de y_i são significativamente maiores que zero.
- **Quando Evitar:** Quando existem valores reais $y_i = 0$ ou muito próximos de zero, ou quando erra-se por superestimativa extrema (o MAPE penaliza mais erros que superestimam do que os que subestimam).

TIPO DE PROBLEMA DE MACHINE LEARNING

REGRESSÃO (Valor Contínuo)

Ex: Preço, Temperatura, Tempo

- MAE (Erro Médio Absoluto)
- MSE (Erro Quadrático Médio)
- RMSE (Raiz do Erro Quadrático Médio)
- MAPE – Erro Percentual Médio Absoluto
- ➡ R² (Coeficiente de Determinação)
- Análise de Resíduos

CLASSIFICAÇÃO (Categorias)

Ex: Churn (Sim/Não), Fraude, Doença

- Matriz de Confusão
- Acurácia
- Precisão
- Recall / Sensibilidade
- F1-Score
- Curva ROC & AUC

R^2 — Coeficiente de Determinação

Intuitivamente:

Todas as métricas anteriores (MAE, MSE, RMSE) medem o erro em termos absolutos ou na escala do problema. Mas responda rápido: *Um RMSE de R\$ 50,00 é bom ou ruim?*

- Se estivermos prevendo o preço de um imóvel de R\$ 1.000.000,00, R\$ 50,00 é um erro minúsculo!
- Se estivermos prevendo o preço de um café de R\$ 10,00, R\$ 50,00 é um erro desastroso!

O R^2 resolve esse dilema. Ele indica a **proporção da variância total da variável alvo que foi explicada pelo seu modelo**, comparando-o com o modelo mais simples e "preguiçoso" possível: aquele que simplesmente chuta a média de y para todas as observações.

R2 – Coeficiente de Determinação

$$R^2 = 1 - \frac{SS_{res}}{SS_{tot}} = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2}$$

- SS_{res} (**Soma dos Quadrados dos Resíduos / Sum of Squared Residuals**): É a soma do erro quadrático acumulado do **seu modelo** ($\sum (y_i - \hat{y}_i)^2$).
- SS_{tot} (**Soma Total dos Quadrados / Total Sum of Squares**): É a soma do erro quadrático acumulado do **modelo de baseline (preguiçoso)**, que usa a média $\bar{y}$ para prever todas as saídas ($\sum (y_i - \bar{y})^2$).
- $\bar{y}$: Média simples de todos os valores reais de y .
- **Interpretando a razão** $\frac{SS_{res}}{SS_{tot}}$: É a proporção de erro que seu modelo *não* conseguiu eliminar em relação ao modelo ingênuo.

R2 – Coeficiente de Determinação

- Interpretando os valores de R^2 :
 - $R^2 = 1.0$ (100%): Modelo perfeito. Erro $SS_{res} = 0$.
 - $R^2 = 0.0$ (0%): Seu modelo não aprendeu nada; performa exatamente igual a chutar a média $\bar{y}$.
 - $R^2 < 0$ (Negativo): O seu modelo consegue ser **pior** do que simplesmente responder a média para tudo. Ocorre com frequência em modelos mal ajustados sem termo de intercepto ou com sobreajuste (*overfitting*) severo em dados de teste.

R² — Coeficiente de Determinação

Impacto de Outliers:

Por utilizar somas quadráticas tanto no numerador (SS_{res}) quanto no denominador (SS_{tot}), o R^2 é sensível a outliers.

Unidade de Medida:

O R^2 é uma métrica adimensional (expressa como um percentual ou valor decimal).

R2 — Coeficiente de Determinação

Quando Usar vs. Quando Evitar

- **Quando Usar:**

- Para comparar a qualidade de ajuste do modelo entre datasets com escalas completamente diferentes.
- Para entender a capacidade explicativa teórica das variáveis preditoras em relação à variável resposta.

- **Quando Evitar:**

- Como métrica isolada de sucesso em produção sem olhar o MAE/RMSE.
- Ao comparar modelos com número muito diferente de variáveis preditoras (para isso, utiliza-se o R^2 **Ajustado**, que penaliza a adição de colunas irrelevantes).

TIPO DE PROBLEMA DE MACHINE LEARNING

REGRESSÃO (Valor Contínuo)

Ex: Preço, Temperatura, Tempo

- MAE (Erro Médio Absoluto)
- MSE (Erro Quadrático Médio)
- RMSE (Raiz do Erro Quadrático Médio)
- MAPE – Erro Percentual Médio Absoluto
- R^2 (Coeficiente de Determinação)
-  Análise de Resíduos

CLASSIFICAÇÃO (Categorias)

Ex: Churn (Sim/Não), Fraude, Doença

- Matriz de Confusão
- Acurácia
- Precisão
- Recall / Sensibilidade
- F1-Score
- Curva ROC & AUC

Análise de Resíduos

A análise de resíduos ($e_i = y_i - \hat{y}_i$) é a ferramenta de **diagnóstico clínico** do modelo. Duas métricas numéricas podem ser iguais, mas a análise de resíduos mostra *como* o modelo falha:


1. **Gráfico de Resíduos vs. Preditos:** Deve parecer uma "nuvem aleatória" ao redor do zero.
2. **Se houver padrão (ex: formato de funil):** O modelo sofre de *heteroscedasticidade* (erra muito em valores altos e pouco em valores baixos).
3. **Se houver formato de curva/U:** O modelo não capturou uma relação não linear importante.

Mesmo que o Modelo A tenha um R^2 levemente pior que o Modelo B, se os resíduos do Modelo A forem aleatórios e os do Modelo B apresentarem um viés sistemático perigoso, o Modelo A pode ser a escolha mais segura para produção.

Suponha a seguinte situação:

- O **Modelo A** erra, em média, R\$ 50,00 por cliente.
- O **Modelo B** também erra, em média, R\$ 50,00 por cliente.

Esses dois modelos possuem a mesma qualidade?



<https://blog.nvidia.com.br/>

Suponha a seguinte situação:

De maneira geral, não fazemos a menor ideia até sabermos COMO esses R\$ 50,00 estão distribuídos (lembre da nossa aula de estatística)!

Se o Modelo A erra R\$ 50,00 em quase todas as pessoas, mas o Modelo B acertar o valor exato para 99% das pessoas e erra R\$ 5.000,00 em um único cliente corporativo, a falha do Modelo B pode quebrar a empresa!

Podemos usar as métricas que vimos para encarar o desafio: **MAE, MSE, RMSE e R^2** ."

Exemplo ilustrativo Considere esse micro-dataset (n = 4 imóveis em milhares de Reais)

Imóvel (i)	Real (y_i)	Predito ($\hat{y}_i$)	Erro ($y_i - \hat{y}_i$)	Absoluto $ y_i - \hat{y}_i $	Quadrático $(y_i - \hat{y}_i)^2$	Erro Relativo $\frac{y_i}{ y_i - \hat{y}_i }$
1	200	210	-10	10	100	$\frac{10}{200} = 0,0500$ (5,0%)
2	300	290	+10	10	100	$\frac{10}{300} = 0,0333$ (3,33%)
3	400	380	+20	20	400	$\frac{20}{400} = 0,0500$ (5,0%)
4	600	700	-100 (<i>Outlier</i>)	100	10.000	$\frac{100}{600} = 0,1667$ (16,67%)
Soma ($\sum$)	1.500	—	0	140	10.600	0,3000 (30,0%)

Passo 1: MAE (Erro Médio Absoluto)

$$MAE = \frac{\sum |y_i - \hat{y}_i|}{n} = \frac{140}{4} = 35$$

Significado: Em média, o modelo erra R\$ 35 mil (R\$ 35.000,00) para mais ou para menos.

Passo 2: MSE (Erro Quadrático Médio)

$$MSE = \frac{\sum (y_i - \hat{y}_i)^2}{n} = \frac{10.600}{4} = 2.650$$

Significado: Erro quadrático de 2.650 (milhares de R\$)². O erro da Casa 4 (100k) gerou uma penalidade pesada (10.000) no LSE acumulado.

Passo 3: RMSE (Raiz do Erro Quadrático Médio)

$$RMSE = \sqrt{MSE} = \sqrt{2.650} \approx 51,48$$

- **Significado:** O RMSE é de **R\$ 51,48 mil** (R\$ 51.480,00).
- **Destaque:** Compare o MAE (35k) com o RMSE (51,48k). O RMSE é maior justamente porque penalizou rigorosamente o erro atípico da Casa 4.

Passo 4: MAPE (Erro Percentual Médio Absoluto)

$$MAPE = \frac{\sum \left| \frac{y_i - \hat{y}_i}{y_i} \right|}{n} \times 100\% = \frac{0,3000}{4} \times 100\% = 7,5\%$$

- **Significado:** Em termos relativos, o modelo erra, em média, 7,5% do valor real do imóvel.
- **Destaque:** Essa métrica é ideal para explicar o desempenho para um diretor (diretoria): *"Nosso modelo tem uma taxa de erro média de 7,5%"*.

Passo 5: R^2 (Coeficiente de Determinação)

Média dos valores reais: $\bar{y} = \frac{1.500}{4} = 375$ mil.

Soma Total dos Quadrados (SS_{tot}):

- Casa 1: $(200 - 375)^2 = (-175)^2 = 30.625$
- Casa 2: $(300 - 375)^2 = (-75)^2 = 5.625$
- Casa 3: $(400 - 375)^2 = (25)^2 = 625$
- Casa 4: $(600 - 375)^2 = (225)^2 = 50.625$
- $SS_{tot} = 87.500$

Passo 5: R^2 (Coeficiente de Determinação)

Cálculo do R^2 :

$$R^2 = 1 - \frac{SS_{res}}{SS_{tot}} = 1 - \frac{10.600}{87.500} = 1 - 0,1211 = 0,8789 \text{ (ou 87,89\%)}$$

- **Significado:** O modelo explica 87,89% da variação nos preços dos imóveis.

Resumo de métricas

Métrica	Unidade	Sensibilidade a Outliers	Principal Vantagem / Caso de Uso
MAE	Igual a y	Baixa (Robusto)	Interpretação simples na moeda/unidade original.
MSE / LSE	Quadrado de y^2	Altíssima	Otimização matemática e treinamento de algoritmos.
RMSE	Igual a y	Alta	Avalia o erro na unidade original penalizando falhas graves.
MAPE	Porcentagem (%)	Alta para $y_i \approx 0$	Comunicação com negócios e comparação entre escalas.
R^2	Adimensional (0 a 1)	Alta	Mede a capacidade explicativa global do modelo.

ATIVIDADE GUIADA

MACHINE LEARNING E PROGRAMAÇÃO | Atividade Prática de Implementação



Criada com Gemini


Métricas para avaliação de Modelos de Machine Learning

MÓDULO 2 - SEMANA 4 - AULA 3


Agenda

- Quais as principais métricas para validação de modelos em ML - Classificação
 - Matriz de confusão

Classificação



$$x \in \mathbb{R}$$



$$x = (x_1, x_2) \in \mathbb{R}^2$$

Nina S. T. Hirata, IME - USP

TIPO DE PROBLEMA DE MACHINE LEARNING

REGRESSÃO (Valor Contínuo)

Ex: Preço, Temperatura, Tempo

- ├ MAE (Erro Médio Absoluto)
- ├ MSE (Erro Quadrático Médio)
- ├ RMSE (Raiz do Erro Quadrático Médio)
- ├ MAPE – Erro Percentual Médio Absoluto
- ├ R^2 (Coeficiente de Determinação)
- └ Análise de Resíduos

CLASSIFICAÇÃO (Categorias)


Ex: Churn (Sim/Não), Fraude, Doença



- ├ Matriz de Confusão
- ├ Acurácia
- ├ Precisão
- ├ Recall / Sensibilidade
- ├ F1-Score
- └ Curva ROC & AUC

Matriz de confusão

Antes de qualquer métrica resumida (como um único número de 0% a 100%), a **Matriz de Confusão** é a radiografia completa do seu modelo. Ela compara o que a realidade diz com o que o modelo previu.



Actual value	Walleye	TP			
	Largemouth Bass		TP		
	Bluegill			TP	
	Rainbow Trout				TP
		Walleye	Largemouth Bass	Bluegill	Rainbow Trout
		Predicted value			

<https://www.ibm.com/br-pt/think/topics/confusion-matrix>

Matriz de confusão

Real	previsão

		Mundo real		
Previsto pelo modelo				

Matriz de confusão

		Classe Real	
		Positivo	Negativo
Classe Prevista	Positivo	Verdadeiro Positivo (VP)	Falso Positivo (FP)
	Negativo	Falso Negativo (FN)	Verdadeiro Negativo (VN)

Actual value	Positive	TP	FN
	Negative	FP	TN
		Positive	Negative
		Predicted value	

Matriz de confusão

- **Verdadeiro Positivo (VP)**
 - Predição correta da classe positiva
 - (previu que é, e de fato é)
- **Verdadeiro Negativo (VN)**
 - Predição correta da classe negativa
 - (previu que não é, e de fato não é)
- **Falso Positivo (FP)**
 - Predição incorreta da classe negativa
 - (previu que é, mas na verdade não é)
 - Chamado de Erro do Tipo 1
- **Falso Negativo (FN)**
 - Predição incorreta da classe positiva
 - (previu que não é, mas na verdade é)
 - Chamado de Erro Tipo 2

		Classe Real	
		Positivo	Negativo
Classe Prevista	Positivo	Verdadeiro Positivo (VP)	Falso Positivo (FP)
	Negativo	Falso Negativo (FN)	Verdadeiro Negativo (VN)

Matriz de confusão

Vamos dar uma olhada nessas interpretações que mais causam confusões:

- **Falso Positivo (FP)**
 - O modelo “disse” que era Positivo, mas na verdade (valor esperado do mundo real) era Negativo.
- **Falso Negativo (FN)**
 - O modelo “disse” que era Negativo, mas na verdade (valor esperado do mundo real) era Positivo.

		Classe Real	
		Positivo	Negativo
Classe Prevista	Positivo	Verdadeiro Positivo (VP)	Falso Positivo (FP)
	Negativo	Falso Negativo (FN)	Verdadeiro Negativo (VN)

Matriz de confusão

Imagine um exame médico para detectar uma doença grave. A Matriz de Confusão cruza duas perguntas:

1. O paciente está doente? (Sim / Não)
2. O teste deu positivo? (Sim / Não)

	Realidade: POSITIVO (1)	Realidade: NEGATIVO (0)
Predição: POSITIVO (1)	Verdadeiro Positivo (VP) (Detectou a doença corretamente)	Falso Positivo (FP) (Alarme Falso — Erro Tipo I)
Predição: NEGATIVO (0)	Falso Negativo (FN) (Paciente doente liberado — Erro Tipo II)	Verdadeiro Negativo (VN) (Pessoa saudável liberada corretamente)

Matriz de confusão

Os Dois Tipos de Erros no Mundo Real

- Falso Positivo (FP / **Erro Tipo I**): O modelo acusa algo que **não** existe.
 - *Exemplo em Fraude*: Bloquear o cartão de um cliente honesto fazendo compras de viagem.
 - *Exemplo em E-mail*: Enviar um e-mail importante de trabalho para a caixa de Spam.
- Falso Negativo (FN / **Erro Tipo II**): O modelo deixa passar algo que **existia**.
 - *Exemplo em Medicina*: Dizer a um paciente com câncer que ele está saudável.
 - *Exemplo em Manutenção*: Dizer que a turbina do avião está perfeita quando há uma trinca.

O custo de negócio do FP e do FN é quase nunca é o mesmo. É esse desequilíbrio que dita qual métrica escolher.

Decodificando os Dois Tipos de Erro

Erro Tipo I (Falso Positivo - FP)

- *"Rejeitar incorretamente uma hipótese nula verdadeira."*
- **O que significa na prática:** Você acusou algo que **NÃO** existia. É o famoso **Alarme Falso**.
- **Tradução:** O paciente está saudável (H_0 é verdade), mas o teste/modelo disse que ele está doente (1).
- **Consequência:** *"Mudanças ou intervenções são desnecessárias, perdemos tempo e recursos."*
 - *Exemplo:* Mandar um e-mail importante do chefe para a lixeira (Spam) ou parar uma fábrica inteira por um alarme falso de sensor.

Decodificando os Dois Tipos de Erro

Erro Tipo II (Falso Negativo - FN)

- *"Falhar em rejeitar uma hipótese nula que é realmente falsa."*
- **O que significa na prática:** Você deixou passar algo que **EXISTIA**. É a **Omissão / Ponto Cego**.
- **Tradução:** O paciente está realmente doente (H_1 é verdade), mas o teste/modelo disse que ele está saudável (0).
- **Consequência:** *"Preservação do status quo quando mudanças são necessárias."*
 - *Exemplo:* Mandar para casa sem tratamento um paciente com uma doença grave, ou liberar uma transação de R\$ 50 mil feita por um hacker.

Como "Escolher" Qual Erro Aceitar no Negócio?

Nós **não escolhemos cometer erros**, mas quando ajustamos o nosso modelo de Machine Learning, somos forçados a fazer um *trade-off* (troca): **qual erro custa mais caro para o meu negócio?**

É aqui que conectamos esse conceito com as métricas **Precisão** e **Recall**

Cenário A: Quando o Erro Tipo II (FN) é Catastrófico

Decisão de Negócio: Precisamos zerar os Falsos Negativos. Aceitamos ter mais Falsos Positivos. **Métrica Priorizada: RECALL (Sensibilidade)**

- **Exemplo 1 (Diagnóstico de Câncer):**

- *Falso Positivo (Tipo I):* Dizer que o paciente tem câncer, mas num exame secundário descobrir que era um alarme falso. (Custo: Ansiedade e gasto com 1 exame extra).
- *Falso Negativo (Tipo II):* Dizer que o paciente está saudável e mandá-lo para casa. O tumor cresce sem tratamento. (Custo: Morte do paciente).
- **Conclusão:** O Erro Tipo II é infinitamente pior. Priorizamos o **Recall**.

- **Exemplo 2 (Segurança em Aviação / Manutenção Preditiva):**

- Melhor parar um avião para checagem por um alarme falso (Tipo I) do que deixar um avião decolar com peça trincada (Tipo II).

Cenário B: Quando o Erro Tipo I (FP) é Catastrófico

Decisão de Negócio: Precisamos zerar os Falsos Positivos. Aceitamos que alguns casos positivos passem despercebidos. **Métrica Priorizada: PRECISÃO**

- **Exemplo 1 (Filtro de Spam):**
 - *Falso Positivo (Tipo I):* Mover a proposta de emprego ou e-mail de um cliente importante para o Spam. (Custo: Perda de negócio/emprego).
 - *Falso Negativo (Tipo II):* Deixar um e-mail de propaganda de sapato passar para a Caixa de Entrada. (Custo: O usuário gasta 1 segundo para deletar).
 - **Conclusão:** O Erro Tipo I é muito pior. Priorizamos a **Precisão**.
- **Exemplo 2 (Concessão Automática de Crédito / Empréstimo):**
 - Dar R\$ 100 mil de crédito para um mal pagador (Tipo I) gera calote direto. Negar crédito para alguém que talvez pagasse (Tipo II) faz a empresa apenas deixar de lucrar juros.

TIPO DE PROBLEMA DE MACHINE LEARNING

REGRESSÃO (Valor Contínuo)

Ex: Preço, Temperatura, Tempo

- ├ MAE (Erro Médio Absoluto)
- ├ MSE (Erro Quadrático Médio)
- ├ RMSE (Raiz do Erro Quadrático Médio)
- ├ MAPE – Erro Percentual Médio Absoluto
- ├ R^2 (Coeficiente de Determinação)
- └ Análise de Resíduos

CLASSIFICAÇÃO (Categorias)

Ex: Churn (Sim/Não), Fraude, Doença

- ├ Matriz de Confusão
- ├ Acurácia
- ├ Precisão
- ├ Recall / Sensibilidade
- ├ F1-Score
- └ Curva ROC & AUC

Acurácia (Accuracy)

A Acurácia é a nota geral da prova. Ela simplesmente responde: ***"De todas as decisões que o modelo tomou (positivas e negativas), qual porcentagem ele acertou?"***

$$Accuracy = \frac{VP+VN}{VP+VN+FP+FN}$$

- **Numerador ($VP + VN$):** Total de acertos do modelo.
- **Denominador ($VP + VN + FP + FN$):** Total de casos analisados (n).

O Paradoxo da Acurácia (Accuracy Paradox)

Em datasets desbalanceados, a Acurácia pode torna-se uma métrica ilusória e até perigosa.

Exemplo Clássico:

Em detecção de transações fraudulentas, 99% dos cartões são legítimos e 1% são fraudes. Se você criar um algoritmo "preguiçoso" que simplesmente responda "*NÃO É FRAUDE*" para absolutamente todas as transações, ele terá 99% de Acurácia, mas será 100% inútil para o negócio, pois deixará passar todas as fraudes.

Unidade e Escala:

Adimensional, variando de 0.0 a 1.0 (ou 0% a 100%).

Quando Usar vs. Quando Evitar

- **Quando Usar:** Apenas em datasets **perfeitamente balanceados** (ex: 50% classe A e 50% classe B) e onde os custos de FP e FN são iguais.
- **Quando Evitar:** Em datasets muito desbalanceados (fraude, doenças raras, detecção de falhas, churn).

TIPO DE PROBLEMA DE MACHINE LEARNING

REGRESSÃO (Valor Contínuo)

Ex: Preço, Temperatura, Tempo

- MAE (Erro Médio Absoluto)
- MSE (Erro Quadrático Médio)
- RMSE (Raiz do Erro Quadrático Médio)
- MAPE – Erro Percentual Médio Absoluto
- R^2 (Coeficiente de Determinação)
- Análise de Resíduos

CLASSIFICAÇÃO (Categorias)

Ex: Churn (Sim/Não), Fraude, Doença

- Matriz de Confusão
- Acurácia
- Precisão
- Recall / Sensibilidade
- F1-Score
- Curva ROC & AUC

Precisão (Precision)

Pense na Precisão como a **taxa de confiabilidade do alarme**. Se o alarme toca, qual é a probabilidade de realmente haver um ladrão na casa?

A Precisão olha **exclusivamente para as previsões POSITIVAS** do modelo e pergunta: *"De tudo o que meu modelo rotulou como Positivo, quanto era realmente Positivo?"*

Precisão (Precision)

$$Precision = \frac{VP}{VP+FP}$$

- **Foco do Denominador ($VP + FP$):** Apenas os casos em que o modelo deu a ordem/alerta de "Positivo".
- **Objetivo:** Minimizar os **Falsos Positivos (FP)**.

Quando Usar vs. Quando Evitar

- **Quando Usar:** Quando o custo do **Falso Positivo (FP)** for extremamente alto para o negócio.
 - *Filtro de Spam:* Mandar um e-mail legítimo da diretoria para o Spam (FP) é pior do que deixar um e-mail de propaganda passar para a caixa de entrada.
 - *Concessão de Crédito Automática:* Dar crédito a quem não tem capacidade de pagamento pode gerar inadimplência direta.
- **Quando Evitar:** Quando não se pode correr o risco de deixar passar casos reais positivos (foco em FN).

TIPO DE PROBLEMA DE MACHINE LEARNING

REGRESSÃO (Valor Contínuo)

Ex: Preço, Temperatura, Tempo

- MAE (Erro Médio Absoluto)
- MSE (Erro Quadrático Médio)
- RMSE (Raiz do Erro Quadrático Médio)
- MAPE – Erro Percentual Médio Absoluto
- R^2 (Coeficiente de Determinação)
- Análise de Resíduos

CLASSIFICAÇÃO (Categorias)

Ex: Churn (Sim/Não), Fraude, Doença

- Matriz de Confusão
- Acurácia
- Precisão
-  — Recall / Sensibilidade
- F1-Score
- Curva ROC & AUC

Recall ou Sensibilidade (Sensitivity)

Pense no Recall como a **capacidade de varredura de uma rede de pesca**. Se existirem 100 peixes no lago, quantos peixes a sua rede conseguiu capturar?

O Recall olha **exclusivamente para a REALIDADE POSITIVA** do dataset e pergunta: *"De todos os casos que ERAM realmente Positivos no mundo real, quantos meu modelo conseguiu encontrar?"*

Recall ou Sensibilidade (Sensitivity)

$$Recall = \frac{VP}{VP+FN}$$

- **Foco do Denominador ($VP + FN$):** O total real de doentes, fraudes ou falhas existentes no dataset.
- **Objetivo:** Minimizar os **Falsos Negativos (FN)**.

Quando Usar vs. Quando Evitar

- **Quando Usar:** Quando o custo do **Falso Negativo (FN)** for catastrófico.
 - *Diagnóstico Médico:* Liberar um doente sem tratamento pode levá-lo a óbito.
 - *Detecção de Fraude Financeira:* Deixar uma transação fraudulenta passar traz prejuízo direto.
- **Quando Evitar:** Isoladamente, se o modelo começar a dar o diagnóstico "Positivo" para todo mundo só para ter 100% de Recall (o que destruiria a Precisão).

TIPO DE PROBLEMA DE MACHINE LEARNING

REGRESSÃO (Valor Contínuo)

Ex: Preço, Temperatura, Tempo

- MAE (Erro Médio Absoluto)
- MSE (Erro Quadrático Médio)
- RMSE (Raiz do Erro Quadrático Médio)
- MAPE – Erro Percentual Médio Absoluto
- R^2 (Coeficiente de Determinação)
- Análise de Resíduos

CLASSIFICAÇÃO (Categorias)

Ex: Churn (Sim/Não), Fraude, Doença

- Matriz de Confusão
- Acurácia
- Precisão
- Recall / Sensibilidade
-  — F1-Score
- Curva ROC & AUC

F1-Score: A Média Harmônica

Existe um cabo de guerra natural entre Precisão e Recall: se você aumenta a sensibilidade do modelo para capturar mais casos positivos (aumentando o Recall), ele inevitavelmente dará mais alarmes falsos (diminuindo a Precisão).

O **F1-Score** é o indicador de equilíbrio. Ele consolida a Precisão e o Recall em um único número através de uma **Média Harmônica**.

F1-Score: A Média Harmônica

$$F1 = 2 \times \frac{Precision \times Recall}{Precision + Recall} = \frac{2}{\frac{1}{Precision} + \frac{1}{Recall}}$$

- **Por que Média Harmônica e não Média Aritmética?**
 - A média aritmética simples de 1.0 (Precisão) e 0.0 (Recall) seria 0.5.
 - A média harmônica **pune valores extremos**. Se a Precisão ou o Recall forem muito baixos (próximos de zero), o F1-Score despenca para perto de zero.

Quando Usar vs. Quando Evitar

- **Quando Usar:** Quando você precisa de um indicador único para comparar modelos em datasets **desbalanceados**, onde tanto os FP quanto os FN têm relevância.
- **Quando Evitar:** Se o negócio tiver uma preferência explícita e desproporcional por evitar FP (use Precisão) ou por evitar FN (use Recall).

Resumo das fórmulas

Mundo real (esperado)	
Previsto (modelo)	Positivo
	Negativo
Positivo	TP = 2000
Negativo	FN = 50
Positivo	FP = 100
Negativo	TN = 10000

		Classe Real	
		Positivo	Negativo
Classe Prevista	Positivo	Verdadeiro Positivo (VP)	Falso Positivo (FP)
	Negativo	Falso Negativo (FN)	Verdadeiro Negativo (VN)

$$Accuracy = \frac{VP+VN}{VP+VN+FP+FN}$$

$$Precision = \frac{VP}{VP+FP}$$

$$Recall = \frac{VP}{VP+FN}$$

$$F1 = 2 \times \frac{Precision \times Recall}{Precision + Recall} = \frac{2}{\frac{1}{Precision} + \frac{1}{Recall}}$$

AVALIAÇÃO DOCENTE

O que você está achando das minhas aulas neste conteúdo?

Clique aqui ou escaneie o QRCode ao lado para avaliar minha aula.

Sinta-se à vontade para fornecer uma avaliação sempre que achar necessário.

